

### EXERCÍCIO COMPUTACIONAL #3

UFMG - EEE920 Sistemas Nebulosos

TAIGUARA MELO TUPINAMBÁS

01 de outubro de 2017

#### Parte 1 – fcm\_dataset

Inicialmente os dados são carregados no MatLab, os parâmetros do *fuzzy c-means* são definidos e os centros são aleatorizados.

```
load('fcm_dataset.mat');

%parametros
m = 2; %c-means
eps = 1e-3; %criterio de parada 1
N = 1e3; %criterio de parada 2
p = 4; %quantidade de centros

%aleatoriza os centros
index = round(size(x,1)*rand(p,1));
c = x(index,:);
```

Foi escolhido um  $m$  igual a 2, conforme indicado em sala de aula. A quantidade de centros foi escolhida com base na imagem plotada dos dados (Figura 2), onde notam-se 4 grupos a serem classificados.




Figura 1 – Dados plotados

A primeira parte do algoritmo consiste no cálculo da matriz de pertinência  $U$ , que depende das distâncias entre cada ponto e cada centro, ou seja uma matriz de tamanho  $800 \times 4$  (quantidade de pontos  $\times$  quantidade de centros).

Para o cálculo das pertinências, foi inicializado uma matriz de zeros e, para cada ponto é verificado se aquele ponto é algum centro e, caso seja é dado o valor 1 para a pertinência daquele ponto naquele centro e 0 para os demais. Caso não seja o próprio centro, é calculado a distância do ponto a todos os centros através da fórmula (2) do artigo de Cannon, Dave & Bezdek (1986).

```

%calcula da matriz de pertinencia
U = zeros(size(x,1),size(c,1));

for i=1:size(x,1)
    %checa se o ponto i é algum centro
    if sum(sum repmat(x(i,:),[4,1])==c))==2;
        [~,ind]=max(repmat(x(i,:),[4,1])==c);
        U(i,:)=0; %atribui 0 de pertinencia aos outros centros
        U(i,ind(1))=1; %atribui 1 de pertinencia ao centro que coincide com o ponto
    else
        %calcula as distancias
        for j=1:size(c,1)
            dist(j) = norm(x(i,:)-c(j,:));
        end
        for j=1:size(c,1)
            s=0;
            %somatoria do denominador conforme o artigo
            for k=1:size(c,1)
                s=s+(dist(j)/dist(k))^2;
            end
            U(i,j) = 1/s;
        end
    end
end

end

```

Em seguida, com base na matriz U, calcula-se novos centros utilizando a fórmula (1) do mesmo artigo.

```

%% novos centros
c_new=zeros(size(c));
for j=1:size(c,1)
    aux=U(:,j).^m; %matriz com as pertinencias daquele centro ao quadrado
    c_new(j,:)=sum([aux aux].*x,1)/sum(aux); %calcula o novo centro j
end

```

Estas etapas de cálculo da matriz U e dos centros são executadas iterativamente, até que algum dos critérios de parada seja atingido: quantidade de iterações maior do que N (1e3) ou a norma da diferença entre o centro novo e o centro antigo seja menor do que o valor de epsilon (1e-3).

Cria-se, desta forma, um loop conforme código abaixo.

```

c_old = zeros(size(c));
iter=0;

while norm(c-c_old)>eps && iter<N

    %calcula da matriz de pertinencia
    U = zeros(size(x,1),size(c,1));

    for i=1:size(x,1)
        %checa se o ponto i é algum centro
        if sum(sum repmat(x(i,:),[4,1])==c))==2;
            [~,ind]=max(repmat(x(i,:),[4,1])==c);
            U(i,:)=0; %atribui 0 de pertinencia aos outros centros

```

```

        U(i,ind(1))=1; %atribui 1 de pertinencia ao centro que coincide com o ponto
    else
        %calcula as distancias
        for j=1:size(c,1)
            dist(j) = norm(x(i,:)-c(j,:));
        end
        for j=1:size(c,1)
            s=0;
            %somatoria conforme o artigo
            for k=1:size(c,1)
                s=s+(dist(j)/dist(k))^2;
            end
            U(i,j) = 1/s;
        end
    end

end

%% novos centros
c_new=zeros(size(c));
for j=1:size(c,1)
    aux=U(:,j).^m; %matriz com as pertinencias daquele centro ao quadrado
    c_new(j,:)=sum([aux aux].*x,1)/sum(aux); %calcula o novo centro j
end

%critérios de parada
c_old=c;
c=c_new;
iter=iter+1

end

```

Ao final das iterações, utiliza-se a matriz de pertinência U para saber qual centro possui maior pertinência para cada ponto, resultando na classificação desejada.

Cada ponto é então colorido conforme o seu centro e os resultados são plotados, para avaliar se a classificação foi feita adequadamente.

```

c_[~,ind]=max(U,[],2);

for k = 1 : length(ind)
    if ind(k)==1
        colorMap(k, :) = [1,0,0]; % Red
    elseif ind(k)==2
        colorMap(k, :) = [0,0,1]; % Blue
    elseif ind(k)==3
        colorMap(k, :) = [0,1,0]; % Green
    elseif ind(k)==4
        colorMap(k, :) = [1,0,1]; % Pink
    end
end

scatter(x(:,1),x(:,2),5,colorMap,'filled')

```

O resultado é apresentado na Figura 2.




Figura 2 – Dados coloridos conforme centros de maior pertinência

Os resultados obtidos pelo algoritmo foram comparados com a saída da função fcm()

```
%% comparacao com a função fcm()
```

```
c_fcm = fcm(x,4)
```

```
c_fcm =
```

```
    3.0120    3.4999
```

```
    2.5012    3.9916
```

```
    3.4940    4.4876
```

```
    4.0014    5.0040
```

```
c =
```

```
    2.5013    3.9916
```

```
    4.0014    5.0040
```

```
    3.4940    4.4876
```

```
    3.0120    3.4999
```

Os centros obtidos pela função fcm() foram exatamente os mesmo obtidos pelo algoritmo desenvolvido, conforme esperado.

## Parte 2 – Regiões de Classificação para 2 dimensões

O algoritmo foi adaptado para fazer a classificação das imagens disponibilizadas no moodle.

Inicialmente, carrega-se a imagem a ser classificada, e transforma os dados em uma matriz em que cada linha seja um ponto da imagem e cada coluna o valor que representa sua cor.

```
img = imread('img03.jpg');

x=zeros(size(img,1)*size(img,2),3);

%% transformando a imagem em uma matriz
ind=0;
for i=1:size(img,1)
    for j=1:size(img,2)
        ind=ind+1;
        x(ind,:)=img(i,j,:);
    end
end
```

Uma vez que os dados foram transformados para o mesmo formato tratado na parte 1, o algoritmo era executado da mesma forma, conforme código a seguir

```
%parametros
m = 2; %c-means
eps = 1e-2; %criterio de parada 1
N = 1e5; %criterio de parada 2
p = 4; %quantidade de centros
n = size(x,1); %qtd de padrões

% %aleatoriza os centros
index = round(n*rand(p,1));
c = x(index,:);

c_old = zeros(size(c));
iter=0;

while norm(c-c_old)>eps && iter<N

    %calcula da matriz de pertinencia
    U = zeros(size(x,1),size(c,1));
    for i=1:size(x,1)
        %checa se o ponto i é algum centro
        if sum(sum(repmat(x(i,:),[p,1])==c))>=3;
            [~,ind]=max(sum(repmat(x(i,:),[p,1])==c,2));
            U(i,:)=0; %atribui 0 de pertinencia aos outros centros
            U(i,ind(1))=1; %atribui 1 de pertinencia ao centro que coincide com o ponto
        else
            %calcula as distancias
            for j=1:size(c,1)
                dist(j) = norm(x(i,:)-c(j,:));
            end
            for j=1:size(c,1)
                s=0;
                %somatoria conforme o artigo
                for k=1:size(c,1)
                    s=s+(dist(j)/dist(k))^2;
                end
                U(i,j) = 1/s;
            end
        end
    end
end
```

```

        end
    end
    end
    %% novos centros
    c_new=zeros(size(c));
    for j=1:size(c,1)
        aux=U(:,j).^m; %matriz com as pertinencias daquele centro ao qua-
drado
        c_new(j,:)=sum(repmat(aux,[1,3]).*x,1)/sum(aux);%calcula o novo
centro j
    end

    %critérios de parada
    c_old=c;
    c=c_new;
    iter=iter+1;

end

```

Ao terminar a classificação, era necessário transformar os dados em imagem novamente, atribuindo a cada ponto as cores do centro de maior pertinência.

Para a imagem ser plotada, foi necessário transformar as variáveis em uint8.

```

%% retornando a imagem
ind=0;
img_class=zeros(size(img,1),size(img,2),3);
for i=1:size(img,1)
    for j=1:size(img,2)
        ind=ind+1;
        [~,centro]=max(U(ind,:));
        img_class(i,j,:)=c(centro,:);
    end
end

image(uint8(img_class))

```

## 2.5 Resultados

O algoritmo foi executado para a imagem 3, variando-se a quantidade de centros (de 2 a 7). Os resultados são apresentados na Figura 3.

Nota-se que todas as cores das balas aparecem apenas para quantidades de centros maior do que 5. A diferença entre a imagem classificada com 6 centros e com 7 centros é muito sutil.

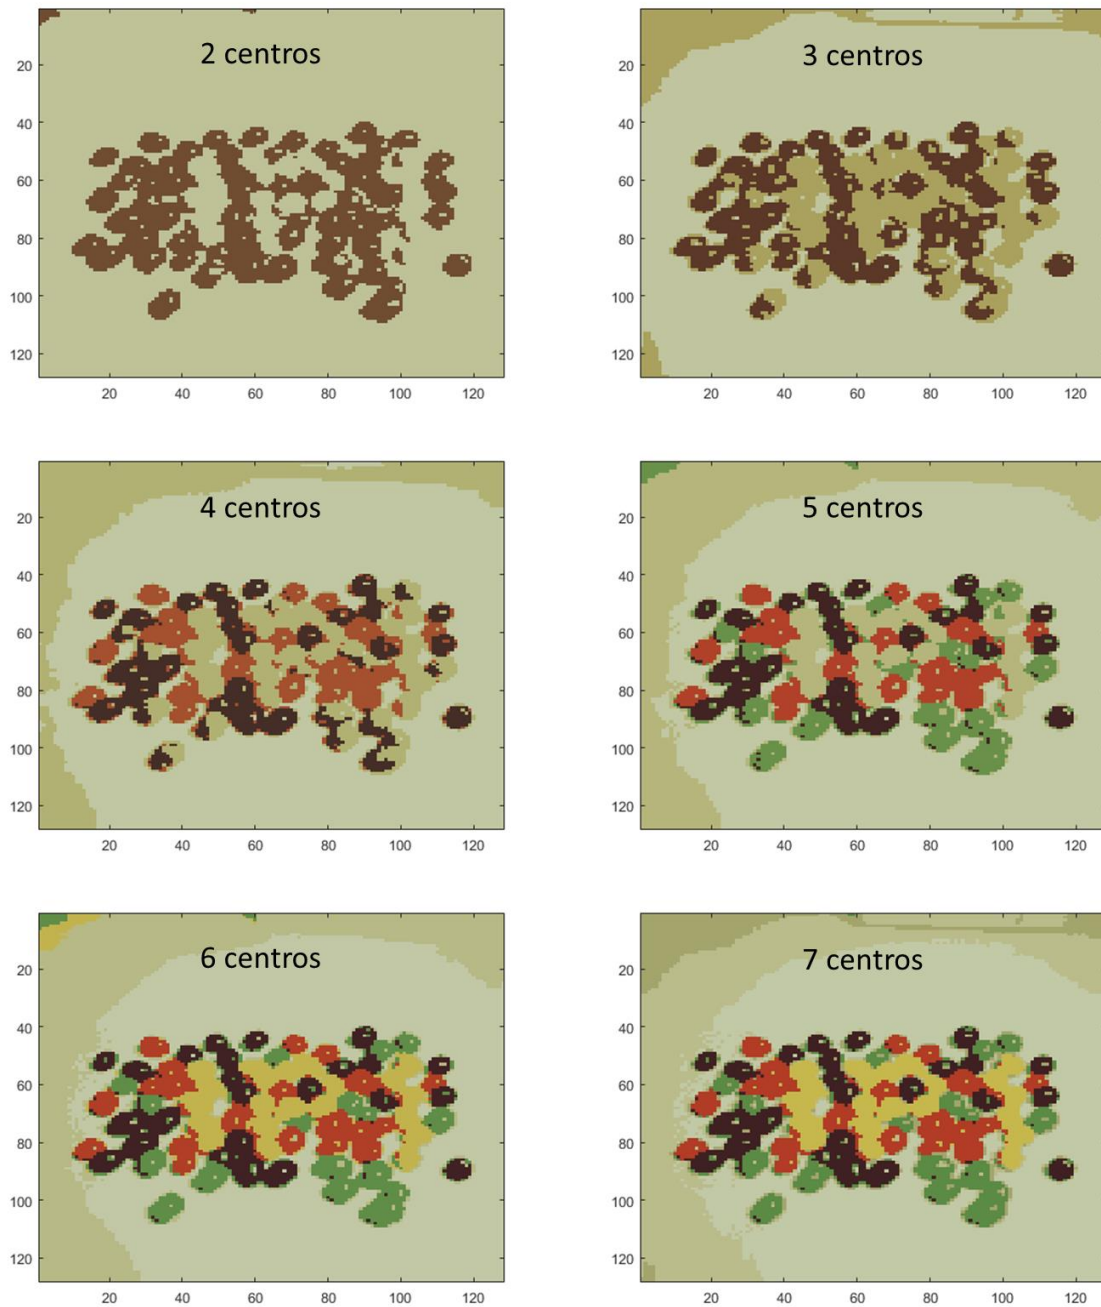


Figura 3 – img03 classificada para diferentes quantidades de centros.

O algoritmo foi comparado com a função `fcm()` para 6 centros, e os valores encontrados foram muito próximos:

`c_fcm =`

177.2482	61.8892	39.2863
96.0946	142.3443	71.8919
194.4292	179.0304	79.4511
64.7794	34.4912	35.7027
183.2395	184.6549	133.7520
193.9716	200.1131	165.6885

`c_algoritmo =`

193.9722	200.1140	165.6911
194.4161	179.0187	79.4584
177.2486	61.8887	39.2861
96.0922	142.3433	71.8910
64.7793	34.4909	35.7026
183.2459	184.6616	133.7622

Em seguida, as outras imagens foram classificadas para uma quantidade de centros arbitrária e os resultados são apresentados nas figuras a seguir

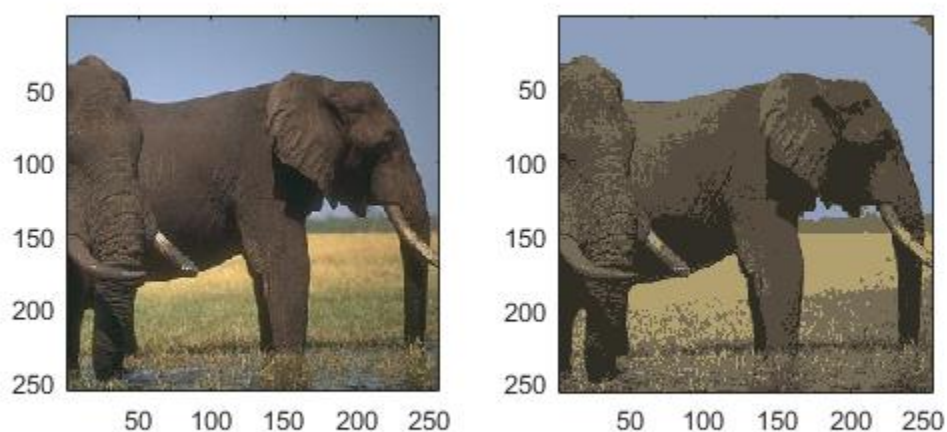


Figura 4 – img-03 original (esquerda) e a classificada com 6 centros (direita)

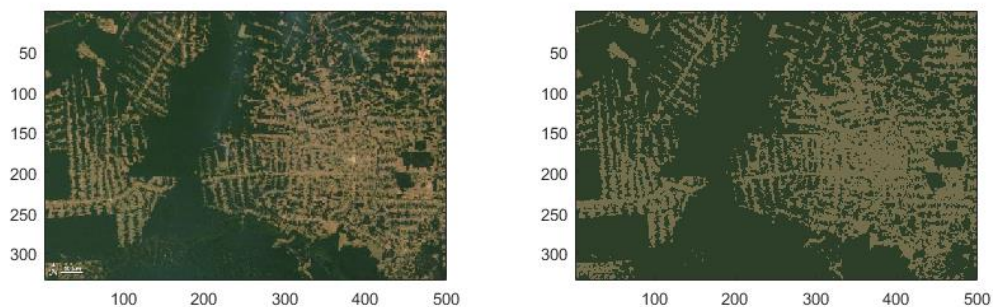


Figura 5 – img2 original (esquerda) e classificada com 2 centros (direita)

### Bibliografia

- [1] R. L. Cannon, J. V. Dave, and J. C. Bezdek, "Efficient Implementation of the Fuzzy c-Means Clustering Algorithms," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. PAMI-8, no. 2, pp. 248–255, 1986.